Graduação em Engenharia de Computação

Trabalho de Conclusão de Curso.

Data da Defesa 09/07/2026

Contra-medidas para Ataques de Falsificação Biométrica em Sistemas Críticos

GUILHERME SILVA TEIXEIRA, OTÁVIO DE SOUZA MARTINS GOMES (Orientador)

RESUMO O avanço de técnicas de geração e manipulação facial por inteligência artificial ampliou os riscos associados ao uso de biometria em sistemas digitais, especialmente em cenários de autenticação remota, entrevistas on-line e videoconferências. Nesse contexto, ataques baseados em deepfakes podem ser utilizados para personificar usuários legítimos, explorar fragilidades em verificações faciais convencionais e apoiar ações de engenharia social. Este trabalho propõe uma análise experimental de ataques de falsificação biométrica em tempo real e investiga contramedidas baseadas em reconhecimento facial, embeddings vetoriais, prova de vida passiva e prova de vida ativa. Para isso, foi desenvolvido um conjunto de quatro laboratórios incrementais, iniciando com reconhecimento facial baseado em embeddings e evoluindo para mecanismos de autenticação com InsightFace, análise temporal de landmarks e desafios do tipo challenge-response. Os experimentos utilizaram o DeepLiveCam para simular tentativas de personificação com rosto sintético visualmente semelhante ao usuário cadastrado. Os resultados preliminares indicam separação consistente entre amostras reais e tentativas de spoofing nas camadas biométricas avaliadas. Como etapa complementar, propõe-se a implementação de uma aplicação desktop de monitoramento contínuo para apoiar a detecção de indícios de manipulação facial em sessões remotas.

PALAVRAS-CHAVE Autenticação biométrica, deepfake, embeddings faciais, liveness detection, reconhecimento facial, sistemas críticos.

I. INTRODUÇÃO

OS sistemas de autenticação biométrica facial tornaram-se comuns em aplicações digitais por oferecerem uma forma rápida e intuitiva de verificação de identidade. Entretanto, a evolução recente de técnicas de síntese facial, troca de rosto e geração de vídeos realistas introduziu novos riscos para sistemas que dependem da aparência visual do usuário como evidência de autenticidade.

Deepfakes evoluíram de demonstrações experimentais para ferramentas acessíveis capazes de reproduzir rostos, expressões e movimentos em tempo real. Em ambientes como entrevistas remotas, reuniões corporativas, validação de identidade e processos seletivos on-line, um atacante pode utilizar uma identidade sintética para tentar se passar por outra pessoa. Esse cenário é especialmente relevante em sistemas críticos, nos quais decisões de acesso, contratação, autorização ou validação dependem da confiança na identidade apresentada.

Este trabalho investiga ataques de falsificação biométrica baseados em deepfakes e avalia contramedidas aplicáveis a sistemas de reconhecimento facial. A proposta parte de experimentos incrementais, organizados em quatro laboratórios, nos quais cada etapa adiciona uma nova camada de defesa ao mecanismo anterior. A evolução considera desde reconhecimento facial convencional por embeddings até validação por prova de vida passiva e ativa.

O objetivo geral deste trabalho é avaliar a resistência de mecanismos biométricos faciais contra ataques de personificação por deepfake em tempo real e propor uma solução de mitigação baseada em múltiplas evidências. Como objetivos específicos, busca-se:

- analisar o comportamento de sistemas de reconhecimento facial diante de uma tentativa de spoofing com DeepLiveCam;
- comparar abordagens baseadas em embeddings faciais convencionais e embeddings vetoriais profundos;
- avaliar o impacto de mecanismos de liveness passivo e ativo;
- definir thresholds experimentais para separação entre usuário legítimo e rosto sintético;

- propor uma aplicação de monitoramento contínuo para videoconferências e entrevistas remotas.

As principais contribuições deste trabalho são: (i) a organização de uma metodologia experimental incremental para avaliar ataques de personificação facial por deepfake em tempo real; (ii) a comparação entre duas estratégias de reconhecimento facial baseadas em embeddings; (iii) a avaliação do comportamento de mecanismos de liveness passivo e ativo diante do DeepLiveCam; (iv) a calibração experimental de thresholds a partir das distâncias observadas entre amostras reais e sintéticas; e (v) a proposta e implementação de uma aplicação desktop para monitoramento contínuo de reuniões e entrevistas remotas.

A lacuna explorada está relacionada ao fato de que muitos mecanismos de autenticação facial avaliam a identidade em um instante específico, enquanto cenários de videoconferência exigem confiança durante toda a sessão. Assim, este trabalho busca aproximar mecanismos biométricos e análise temporal de um contexto prático no qual o atacante pode não precisar vencer uma autenticação formal, mas apenas convencer visualmente os demais participantes.

II. REVISÃO BIBLIOGRÁFICA

A. DEEPFAKES E FALSIFICAÇÃO BIOMÉTRICA

Deepfakes são conteúdos sintéticos gerados ou manipulados por modelos de aprendizado profundo com o objetivo de substituir, modificar ou simular características humanas em imagens, vídeos ou áudios. Em ataques de falsificação biométrica, essas técnicas podem ser utilizadas para apresentar uma face artificialmente compatível com a identidade de uma vítima.

Ferramentas de troca facial em tempo real ampliam esse risco porque permitem que a personificação ocorra durante uma chamada de vídeo ou diante de uma webcam. Nesses casos, o atacante não precisa apenas gerar uma imagem estática convincente; ele precisa manter coerência visual, movimento facial e resposta temporal suficientes para enganar pessoas ou sistemas automatizados.

B. RECONHECIMENTO FACIAL POR EMBEDDINGS

O reconhecimento facial moderno frequentemente representa uma face como um vetor numérico, denominado embedding facial. Esse vetor codifica características discriminativas da identidade, permitindo comparar duas faces por meio de métricas de distância ou similaridade.

O FaceNet, proposto por Schroff, Kalenichenko e Philbin [6], consolidou uma abordagem de aprendizado de embeddings em que imagens faciais são projetadas em um espaço vetorial no qual faces da mesma pessoa tendem a ficar próximas e faces de pessoas diferentes tendem a ficar distantes. Essa ideia fundamenta o uso de thresholds para aceitar ou rejeitar uma autenticação com base na distância entre o embedding cadastrado e o embedding capturado.

C. ARCFACE E EMBEDDINGS PROFUNDOS

Abordagens mais recentes de reconhecimento facial utilizam funções de perda projetadas para aumentar a separabilidade entre identidades. O ArcFace, proposto por Deng et al. [7], utiliza uma margem angular aditiva para melhorar a discriminação entre classes no espaço de características. Essa técnica tornou-se uma referência em reconhecimento facial profundo e é associada a implementações amplamente utilizadas, como modelos disponíveis no ecossistema InsightFace.

No contexto deste trabalho, embeddings profundos são empregados para tornar a verificação biométrica mais robusta e reduzir a probabilidade de aceitação de uma identidade sintética visualmente semelhante ao usuário real.

D. PROVA DE VIDA PASSIVA E ATIVA

Mecanismos de prova de vida, ou liveness detection, buscam verificar se a face apresentada pertence a uma pessoa real presente no momento da autenticação. A prova de vida passiva observa sinais naturais, como variação temporal, micromovimentos e alterações em landmarks faciais, sem exigir uma ação explícita do usuário. Já a prova de vida ativa solicita desafios, como virar a cabeça, piscar ou olhar para uma direção específica, exigindo resposta correta dentro de uma janela de tempo.

Essas abordagens são relevantes porque ataques por deepfake podem reproduzir aparência e alguns movimentos, mas tendem a apresentar limitações quando submetidos a validações temporais, desafios aleatórios e combinações de múltiplas evidências.

III. METODOLOGIA

A metodologia foi estruturada em quatro laboratórios incrementais. Cada laboratório avaliou uma camada de segurança e serviu de base para a etapa seguinte. O ataque experimental foi conduzido com auxílio do DeepLiveCam, utilizando uma identidade facial sintética selecionada por similaridade visual em relação ao usuário cadastrado.

A. SELEÇÃO DO ROSTO SINTÉTICO

Antes da execução dos ataques com DeepLiveCam, foi realizada uma etapa de validação morfológica para orientar a escolha do rosto sintético utilizado nos experimentos. Essa etapa não teve como objetivo clonar a identidade do usuário real nem comparar embeddings biométricos. O procedimento extraiu proporções faciais adimensionais a partir de 68 pontos faciais, gerando uma especificação estrutural utilizada para selecionar uma pessoa fictícia com características morfológicas semelhantes às do participante. Essas proporções representam apenas parte das características biométricas faciais e não correspondem à representação completa aprendida pelos modelos de reconhecimento facial baseados em embeddings.

Foram processadas 27 amostras válidas e 1 quadro foi rejeitado por baixa qualidade. A variabilidade interna da forma normalizada foi de 0,014499, indicando estabilidade descritiva para o conjunto analisado. A Tabela 1 apresenta

as principais proporções utilizadas para orientar a seleção do rosto sintético. Com base nessas proporções, foi escolhida a imagem apresentada na Fig. 1, posteriormente aplicada no DeepLiveCam como identidade de ataque nos LAB01, LAB02, LAB03 e LAB04.

TABLE 1. Proporções morfológicas utilizadas na escolha do rosto sintético

Métrica	Média	Mediana	Desvio
Largura/altura do rosto	1,3057	1,3577	0,1087
Distância olhos/largura rosto	0,4420	0,4479	0,0113
Largura nariz/largura rosto	0,2255	0,2277	0,0056
Largura boca/largura rosto	0,3590	0,3656	0,0139
Terço inferior/altura rosto	0,5930	0,5950	0,0094
Largura mandíbula/largura rosto	0,7617	0,7604	0,0084

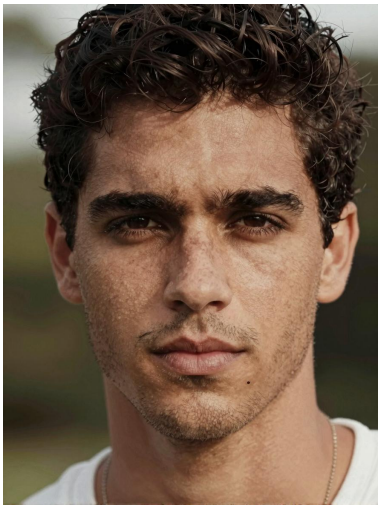


FIGURE 1. Rosto sintético selecionado pela validação morfológica e utilizado no DeepLiveCam como identidade de ataque nos LAB01 a LAB04.

O prompt de geração utilizado restringiu explicitamente a criação a uma pessoa adulta fictícia, com pose frontal, expressão neutra, iluminação uniforme e sem reprodução de marcas, textura de pele ou detalhes exclusivos do usuário real. Dessa forma, a etapa morfológica serviu apenas para aumentar a plausibilidade visual do ataque em ambiente controlado, preservando a distinção biométrica entre o participante e a identidade sintética. Nos laboratórios, essa imagem foi carregada no DeepLiveCam para simular a personificação do usuário cadastrado diante das camadas de autenticação avaliadas.

Antes dos testes, foi realizado o cadastro biométrico do usuário legítimo. Essa etapa gerou a referência utilizada pelas autenticações posteriores e serviu como ponto de comparação para as tentativas de personificação. A Fig. 2 apresenta a face cadastrada utilizada como base dos experimentos.

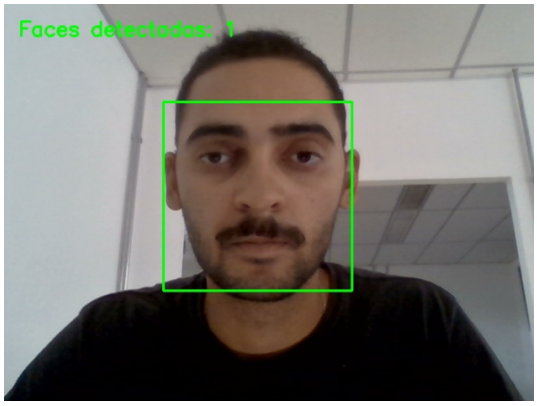


FIGURE 2. Face cadastrada como referência biométrica do usuário legítimo.

B. PROTOCOLO EXPERIMENTAL

Após o cadastro biométrico, cada laboratório foi avaliado por meio de 20 simulações controladas: 10 verificações com o rosto real do usuário cadastrado e 10 verificações com o rosto sintético aplicado no DeepLiveCam. Essa divisão permitiu comparar, em cada camada de autenticação, o comportamento esperado para uma tentativa legítima e para uma tentativa de personificação.

A definição dos thresholds foi feita a partir das métricas produzidas por cada laboratório. Nos LAB01 e LAB02, a métrica principal foi a distância entre embeddings, considerando que valores menores indicam maior similaridade com a referência cadastrada. O threshold foi escolhido entre a maior distância observada nas amostras reais e a menor distância observada nas amostras sintéticas, buscando manter uma margem de separação entre as classes. No LAB03, o threshold de identidade do LAB02 foi mantido e a variação temporal dos landmarks foi analisada como métrica complementar de liveness passivo. No LAB04, a decisão combinou a distância biométrica herdada do LAB02 com a validação da sequência de desafios ativos.

Para cada laboratório, foram registradas evidências visuais de autenticação legítima e de rejeição da tentativa de spoofing. A nomenclatura dos arquivos foi padronizada da seguinte forma: imagens nomeadas como *LABxx* representam a autenticação aceita do usuário legítimo, enquanto imagens nomeadas como *LABxxrej* representam a rejeição da tentativa de personificação.

TABLE 2. Organização dos laboratórios experimentais

Lab	Camada avaliada	Critério principal
LAB01	Embeddings faciais convencionais	Distância facial
LAB02	InsightFace e distância L2	Distância vetorial profunda
LAB03	Identidade e liveness passivo	Identidade e variação temporal
LAB04	Challenge-response ativo	Identidade e resposta ao desafio

IV. RESULTADOS E DISCUSSÃO

A. LAB01: RECONHECIMENTO FACIAL CONVENCIONAL

O LAB01 teve como objetivo avaliar uma camada inicial de autenticação facial baseada em embeddings convencionais. Essa etapa foi implementada com a biblioteca *face_recognition*, baseada em modelos derivados do ecossistema *dlib*, e fundamentada no princípio de representação vetorial de faces popularizado por abordagens como o FaceNet. Nesse tipo de técnica, cada rosto detectado na imagem é transformado em um vetor numérico que representa características discriminativas da face, permitindo comparar matematicamente duas amostras faciais.

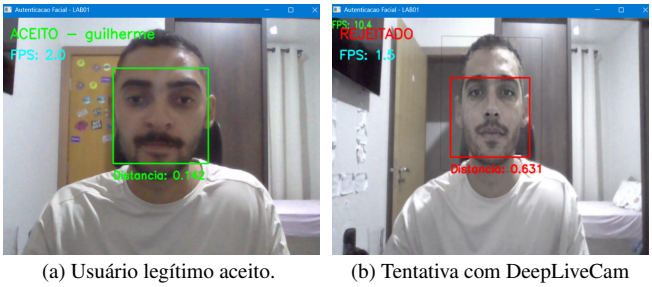
O funcionamento do LAB01 pode ser dividido em três etapas principais. Primeiro, a face do usuário legítimo foi cadastrada e convertida em um embedding de referência. Em seguida, durante a autenticação, a câmera capturou novos quadros em tempo real e extraiu o embedding da face detectada. Por fim, o sistema calculou a distância entre o embedding cadastrado e o embedding capturado. Como a métrica representa distância, valores menores indicam maior similaridade facial, enquanto valores maiores indicam menor compatibilidade com o usuário cadastrado.

Para definir o threshold, foram realizadas 20 simulações: 10 com o usuário real e 10 com a tentativa de personificação via DeepLiveCam. As distâncias do usuário legítimo permaneceram entre aproximadamente 0,207 e 0,237, enquanto as tentativas com deepfake ficaram entre aproximadamente 0,662 e 0,688. Como não houve sobreposição entre os grupos, foi adotado o threshold de 0,45, posicionado entre a maior distância real e a menor distância obtida no ataque. Assim, distâncias menores ou iguais a 0,45 foram consideradas compatíveis com o usuário cadastrado, enquanto valores superiores foram rejeitados.

A Tabela 3 resume a calibração do threshold no LAB01. Em seguida, a Fig. 3 apresenta, lado a lado, uma autenticação legítima aceita e uma tentativa de personificação rejeitada. A Fig. 4 complementa a análise com a distribuição das distâncias obtidas nas 20 simulações.

TABLE 3. Calibração do threshold no LAB01

Classe	Faixa	Threshold	Resultado
Usuário real	0,207–0,237	0,45	Aceito
DeepLiveCam	0,662–0,688	0,45	Rejeitado



(a) Usuário legítimo aceito. (b) Tentativa com DeepLiveCam rejeitada.

FIGURE 3. LAB01: comparação entre autenticação legítima e tentativa de personificação.

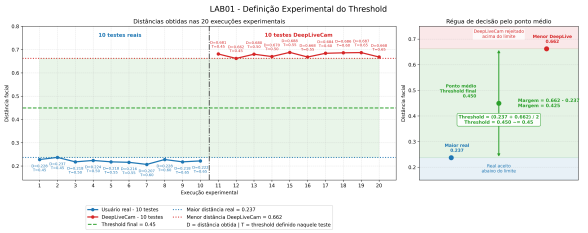


FIGURE 4. LAB01: gráfico de threshold completo, com distribuição das distâncias faciais para usuário real e DeepLiveCam.

B. LAB02: RECONHECIMENTO COM INSIGHTFACE

O LAB02 substituiu a abordagem inicial por embeddings vetoriais profundos gerados com o InsightFace. Essa ferramenta utiliza modelos de reconhecimento facial baseados em redes neurais profundas, capazes de produzir representações mais discriminativas da identidade facial. Diferentemente do LAB01, que empregou uma abordagem convencional de embeddings, o LAB02 utilizou o modelo *buffalo_l*, associado ao ecossistema InsightFace, para detecção facial, alinhamento e extração de embeddings.

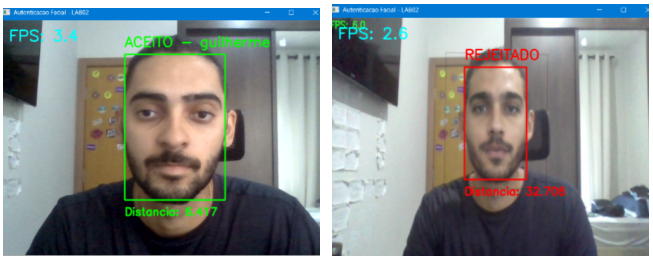
A técnica aplicada no LAB02 segue a lógica de verificação biométrica 1:1. O sistema não procura identificar uma pessoa em um banco de vários usuários; ele verifica se a face observada corresponde ao perfil previamente cadastrado. Para isso, cada face é convertida em um vetor de características e comparada com a referência do usuário por meio da distância L2. Quanto menor a distância L2, maior a similaridade entre as faces. Essa abordagem permitiu avaliar se um modelo de embeddings profundos ofereceria maior separação entre o usuário legítimo e o rosto sintético aplicado pelo DeepLiveCam.

O threshold foi definido de forma experimental a partir das 20 simulações do laboratório: 10 verificações com o usuário real e 10 verificações com o DeepLiveCam. A maior distância real foi 7,893 e a menor distância do DeepLiveCam foi 32,527, resultando em uma margem entre classes de 24,634. O threshold final foi fixado em 20,210, em uma região intermediária entre as duas distribuições. Assim, valores menores ou iguais a 20,210 foram considerados compatíveis com o usuário cadastrado, e valores superiores foram rejeitados.

A Tabela 4 apresenta o critério de decisão do LAB02. A Fig. 5 mostra, lado a lado, uma autenticação real aceita com InsightFace e a rejeição do rosto sintético. A Fig. 6 apresenta o gráfico de threshold completo, evidenciando a separação entre as distâncias reais e sintéticas.

TABLE 4. Critério de decisão no LAB02

Teste	Distância	Threshold	Resultado
Usuário real	até 7,893	20,210	Aceito
DeepLiveCam	a partir de 32,527	20,210	Rejeitado



(a) Usuário legítimo aceito. (b) Tentativa com DeepLiveCam rejeitada.

FIGURE 5. LAB02: comparação entre autenticação legítima e tentativa de spoofing com InsightFace.

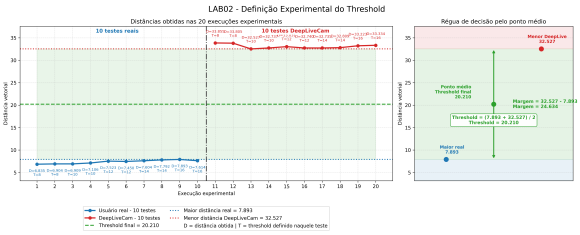


FIGURE 6. LAB02: gráfico de threshold completo, com separação entre usuário real e DeepLiveCam usando embeddings profundos do InsightFace.

C. LAB03: IDENTIDADE E LIVENESS PASSIVO

O LAB03 combinou a verificação de identidade do LAB02 com uma camada de prova de vida passiva. O objetivo foi avaliar se sinais naturais de movimento facial poderiam aumentar a robustez da autenticação sem exigir uma ação explícita do usuário. Para isso, o threshold de identidade de 20,210 foi mantido, pois já havia sido calibrado no LAB02, e uma nova métrica temporal foi adicionada ao processo de decisão.

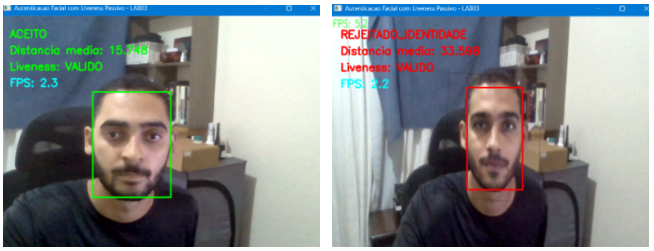
A técnica de liveness passivo utilizada neste laboratório analisou uma sequência de frames capturados pela câmera. A partir desses quadros, o sistema observou a variação temporal da face e o deslocamento dos landmarks faciais. Landmarks são pontos de referência associados a regiões como olhos, nariz, boca e contorno facial. A hipótese avaliada foi que uma face real deveria apresentar pequenas variações naturais ao longo do tempo, enquanto uma tentativa de spoofing poderia apresentar comportamento mais rígido, instável ou artificial.

O protocolo manteve 20 simulações, sendo 10 com o rosto real e 10 com o rosto sintético via DeepLiveCam. Os resultados mostraram que a variação temporal pode contribuir como evidência complementar, mas não deve ser usada isoladamente como prova definitiva de autenticidade. O menor valor de variação temporal observado para o usuário real foi 2,5203, enquanto o maior valor observado para o DeepLiveCam foi 5,289, gerando sobreposição de 2,7687 entre as faixas. Como houve sobreposição entre amostras reais e sintéticas, a variação temporal não recebeu um threshold único definitivo; ela foi tratada como métrica auxiliar combinada ao threshold de identidade. Assim, a variação temporal isolada não apresentou separação tão forte quanto a identidade biométrica.

A Tabela 5 resume a regra combinada utilizada no LAB03. A Fig. 7 apresenta, lado a lado, uma autenticação aceita e uma tentativa de personificação rejeitada. Por fim, a Fig. 8 mostra o gráfico de variação temporal, evidenciando por que essa métrica foi tratada como complementar.

TABLE 5. Critério combinado no LAB03

Camada	Critério	Decisão
Identidade	Distância $\leq 20,210$	Necessária para aceitar
Liveness passivo	Variação mínima testada entre 1,0 e 3,0	Evidência complementar



(a) Usuário legítimo aceito. (b) Tentativa com DeepLiveCam rejeitada.

FIGURE 7. LAB03: comparação entre autenticação legítima e tentativa de personificação com liveness passivo.

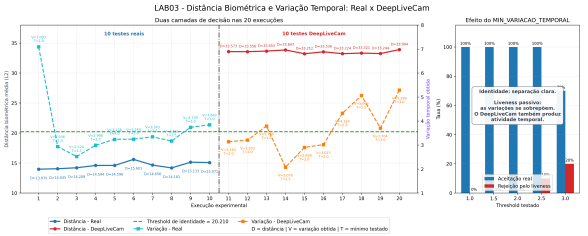


FIGURE 8. LAB03: gráfico de variação temporal, com análise da distância biométrica e do liveness passivo para usuário real e DeepLiveCam.

D. LAB04: IDENTIDADE E CHALLENGE-RESPONSE

O LAB04 adicionou uma camada de prova de vida ativa baseada em *challenge-response*. Diferentemente do liveness passivo, que apenas observa sinais naturais, o challenge-response exige que o usuário execute uma sequência de ações solicitadas pelo sistema. O objetivo foi avaliar se uma deepfake em tempo real conseguiria reproduzir não apenas a aparência facial, mas também respostas comportamentais dinâmicas durante a autenticação.

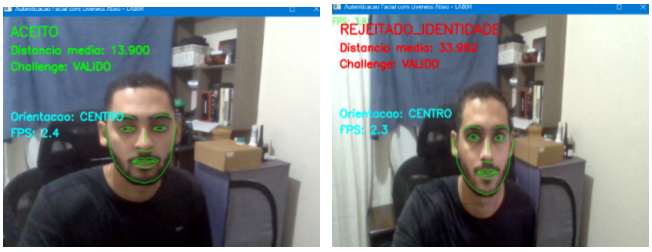
A técnica implementada combinou duas verificações obrigatórias. A primeira foi a identidade biométrica, mantida pela distância L2 entre embeddings do InsightFace e pelo threshold de 20,210 calibrado no LAB02. A segunda foi a validade do desafio ativo, medida pela execução correta de movimentos como virar a cabeça e piscar dentro de uma janela de tempo. A autenticação somente foi aceita quando a face observada permaneceu compatível com o usuário cadastrado e a sequência de desafios foi concluída corretamente.

O laboratório foi avaliado com 20 simulações, sendo 10 reais e 10 com DeepLiveCam. Essa abordagem fortalece a autenticação porque dificulta ataques baseados apenas em aparência facial. Entretanto, os testes também mostraram que a deepfake pode reproduzir parte dos movimentos herdados do operador, o que reforça a conclusão de que liveness ativo não deve ser interpretado como prova isolada de autenticidade. Dessa forma, o LAB04 representa a camada mais completa entre os experimentos realizados por combinar identidade biométrica, resposta comportamental e coerência temporal.

A Tabela 6 apresenta a regra de decisão combinada do LAB04. A Fig. 9 mostra, lado a lado, a autenticação aceita e a rejeição da tentativa de ataque. A Fig. 10 apresenta o gráfico de métricas do laboratório, reunindo distância biométrica, tempo de execução e validade dos desafios.

TABLE 6. Critério combinado no LAB04

Camada	Critério	Decisão
Identidade	Distância $\leq 20,210$	Necessária para aceitar
Challenge-response	Sequência válida	Necessária para aceitar



(a) Usuário legítimo aceito. (b) Tentativa com DeepLiveCam rejeitada.

FIGURE 9. LAB04: comparação entre autenticação legítima e tentativa de ataque com challenge-response.

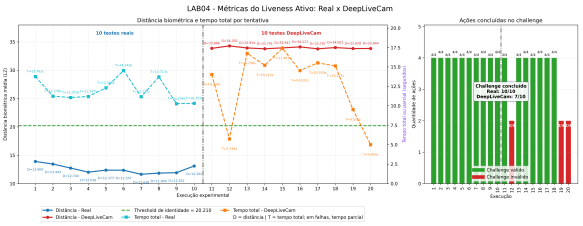


FIGURE 10. LAB04: gráfico de métricas da autenticação com identidade biométrica e challenge-response ativo.

Os gráficos quantitativos complementam as tabelas ao mostrar visualmente a separação entre amostras reais e tentativas de spoofing. Essa organização permite que a análise seja lida em três níveis: descrição textual do método, tabela com critério de decisão e evidência visual da execução.

V. DISCUSSÃO DOS RESULTADOS

Os quatro laboratórios demonstram uma evolução incremental das camadas de defesa avaliadas. No LAB01, a autenticação baseada em embeddings convencionais já apresentou separação entre o usuário legítimo e o rosto sintético utilizado no DeepLiveCam. Embora essa abordagem seja mais simples, ela foi suficiente para rejeitar as tentativas de personificação no cenário controlado, pois as distâncias das amostras sintéticas permaneceram acima do threshold definido experimentalmente.

No LAB02, o uso do InsightFace ampliou a robustez da representação biométrica. A distância L2 entre embeddings profundos produziu uma separação expressiva entre as amostras reais e as amostras com DeepLiveCam, reforçando que a similaridade visual entre rostos não implica, necessariamente, compatibilidade biométrica no espaço vetorial. Esse resultado é importante porque mostra que a deepfake utilizada conseguiu produzir uma aparência plausível para observadores humanos, mas não conseguiu reproduzir a identidade facial extraída pelo modelo.

O LAB03 evidenciou uma limitação relevante dos mecanismos de liveness passivo. A variação temporal e os movimentos dos landmarks indicaram atividade facial, mas apresentaram sobreposição entre usuário real e DeepLiveCam. Isso significa que movimento natural, por si só, não deve ser considerado prova suficiente de autenticidade, principalmente em ataques de face swap em tempo real, nos quais os movimentos do operador podem ser transferidos para o rosto sintético.

O LAB04 reforçou essa conclusão ao adicionar desafios ativos. A exigência de movimentos específicos aumenta a dificuldade operacional do ataque, mas não elimina completamente a capacidade da deepfake de reproduzir ações como piscadas e movimentos de cabeça. Assim, os resultados indicam que a camada mais confiável nos experimentos foi a verificação biométrica por embeddings, enquanto os mecanismos de liveness funcionaram melhor como evidências complementares.

A principal implicação desses resultados é que a defesa contra deepfakes não deve depender de uma única evidência. Em sistemas críticos, a decisão deve combinar identidade biométrica, qualidade da captura, sinais de liveness, análise temporal e persistência das anomalias. Essa interpretação motivou a proposta de implementação descrita na seção seguinte, na qual a autenticação deixa de ser um evento pontual e passa a ser tratada como um processo de monitoramento contínuo durante a videoconferência.

VI. PROPOSTA DE IMPLEMENTAÇÃO

A partir dos resultados dos laboratórios, observou-se que o DeepLiveCam não superou as camadas de identidade biométrica avaliadas. Entretanto, em videoconferências e entrevistas remotas, o atacante não precisa necessariamente burlar um mecanismo formal de autenticação: ele pode utilizar a personificação visual para convencer outros participantes e apoiar ataques de engenharia social. Por esse motivo, a mitigação proposta desloca o foco da autenticação pontual para o monitoramento contínuo da sessão.

Foi desenvolvida uma prova de conceito de uma aplicação desktop executada em paralelo a plataformas como Google Meet, Zoom, Microsoft Teams e Discord. A solução não

exige integração direta com essas ferramentas. O responsável seleciona a janela da reunião ou uma região específica do participante, e o sistema realiza a captura local da área escolhida. Antes da sessão, o participante é cadastrado por imagem ou vídeo de referência, a partir do qual são extraídos embeddings faciais, métricas de qualidade e uma baseline individual para comparação posterior.

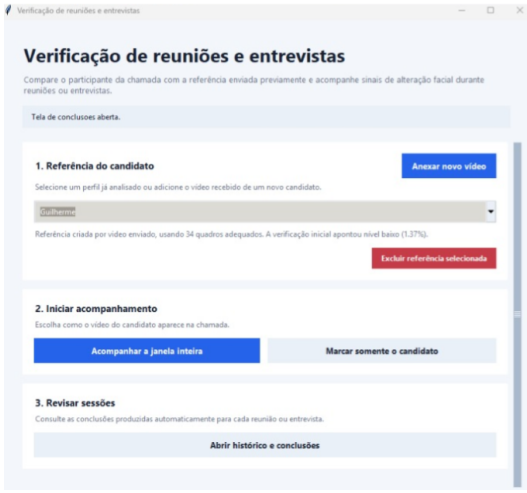


FIGURE 11. Interface do verificador de reuniões proposto para monitoramento contínuo de indícios de deepfake durante videoconferências.

Durante a reunião, o monitor executa verificações periódicas e produz conclusões parciais em intervalos de aproximadamente 30 segundos. Em cada ciclo, são avaliadas a correspondência da identidade facial, possíveis indícios de manipulação sintética, sinais de liveness passivo, qualidade da captura e persistência das anomalias ao longo do tempo. As evidências são combinadas para gerar um risco instantâneo e acumulado da sessão.

A verificação de identidade utiliza o InsightFace, especialmente o modelo *buffalo_l*, para detecção facial, extração de landmarks e geração de embeddings biométricos [15]. Cada face observada é convertida em um vetor numérico e comparada com a referência cadastrada por distância L2. O threshold de identidade utilizado na aplicação foi herdado da calibração experimental do LAB02, mantendo a mesma lógica de decisão: distâncias menores indicam maior compatibilidade com o participante cadastrado.

A análise de manipulação facial utiliza como detector principal o Effort AIGI Detection, baseado em CLIP-L/14, para estimar sinais visuais associados a imagens sintéticas ou manipuladas por IA [16]. Como mecanismo auxiliar, foi integrado um detector baseado na implementação EfficientNet-B7 do desafio DFDC, disponibilizada por Selim Seferbekov, executado localmente em formato ONNX [17], [20]. O objetivo dessa combinação não é produzir uma acusação automática, mas fornecer evidências complementares quando houver aumento de sinais de manipulação em relação à referência do participante.

Além da identidade e da detecção de deepfake, a aplicação utiliza OpenCV para processamento dos frames capturados, recorte facial, cálculo de nitidez, brilho, diferenças temporais e métricas visuais de qualidade [19]. Essas métricas impedem que quadros com baixa iluminação, rosto pequeno, baixa nitidez ou baixa confiança de detecção sejam interpretados como evidências definitivas. O liveness passivo é calculado por variação temporal e deslocamento de landmarks, sendo tratado apenas como evidência auxiliar, pois os LAB03 e LAB04 demonstraram que movimento natural, piscada e resposta a comandos podem ser parcialmente reproduzidos por ferramentas de face swap em tempo real.

A arquitetura da aplicação pode ser resumida em quatro camadas principais:

- **identidade facial**: comparação de embeddings extraídos com InsightFace em relação à referência cadastrada;
- **detecção de manipulação**: análise de sinais visuais associados a deepfakes por Effort e, de forma auxiliar, por EfficientNet-B7 treinado no DFDC;
- **liveness e qualidade**: avaliação de movimento facial, landmarks, iluminação, nitidez, tamanho da face e confiança da detecção;
- **persistência temporal**: agregação dos sinais ao longo da sessão para reduzir decisões baseadas em eventos isolados.

Os principais projetos utilizados na implementação foram InsightFace, Effort AIGI Detection, DFDC EfficientNet-B7, OpenCV e ONNX Runtime. A contribuição deste trabalho não está no treinamento de um novo modelo de inteligência artificial, mas na integração dessas técnicas em uma arquitetura aplicada ao monitoramento contínuo de videoconferências. Dessa forma, a solução combina reconhecimento facial, detecção de manipulação, avaliação de qualidade e persistência temporal para apoiar a decisão humana em cenários de risco.

O sistema não realiza acusação automática de fraude. Ao final da entrevista, a ferramenta apresenta um resumo da sessão, os principais indícios observados e um nível de risco para apoiar a decisão do recrutador ou responsável. Por padrão, o armazenamento é local e restrito a métricas, embeddings e avaliações, sem gravação de frames ou vídeos da reunião.

VII. LIMITAÇÕES E TRABALHOS FUTUROS

Apesar dos resultados obtidos, este trabalho possui limitações que devem ser consideradas. Os experimentos foram conduzidos em ambiente controlado, utilizando um conjunto específico de ferramentas, câmera, iluminação e condições de captura. Além disso, o ataque foi avaliado com o DeepLive-Cam e com um rosto sintético selecionado para o experimento, não abrangendo todas as ferramentas de face swap em tempo real disponíveis.

Outra limitação está relacionada ao número de participantes e ao escopo das amostras. A calibração dos thresholds foi realizada com base nas execuções controladas do usuário cadastrado e da identidade sintética definida para os testes. Embora essa abordagem seja adequada para uma

prova de conceito e para análise experimental inicial, estudos futuros devem ampliar o número de usuários, rostos sintéticos, condições de iluminação, câmeras e plataformas de videoconferência.

Também deve ser considerada a impossibilidade de reproduzir integralmente os mecanismos de autenticação empregados por sistemas comerciais. Em geral, empresas responsáveis por plataformas de autenticação biométrica não divulgam detalhes sobre suas arquiteturas, modelos de reconhecimento facial, thresholds de decisão ou estratégias de mitigação, por questões de segurança e proteção contra engenharia reversa. Dessa forma, os experimentos foram conduzidos utilizando técnicas amplamente consolidadas na literatura científica e em projetos de código aberto, como reconhecimento facial baseado em embeddings, liveness passivo e ativo e detectores de manipulação facial. Embora essa abordagem não reproduza exatamente implementações proprietárias, ela permite avaliar o comportamento do DeepLive-Cam frente a mecanismos representativos do estado da arte.

Como trabalhos futuros, propõe-se avaliar a solução com outras ferramentas de geração e troca facial em tempo real, testar cenários com múltiplos participantes, incluir análise de áudio e voz, aprimorar os detectores de manipulação facial e validar a aplicação de monitoramento contínuo em entrevistas remotas reais ou simuladas com maior diversidade de ambientes. Também é relevante investigar estratégias de fusão multimodal que combinem identidade facial, sinais de voz, comportamento temporal e metadados da sessão.

VIII. CONCLUSÃO

Este trabalho apresentou uma análise experimental de contramedidas para ataques de personificação facial utilizando deepfakes em tempo real. A partir de quatro laboratórios incrementais, foi possível avaliar o comportamento de diferentes mecanismos de autenticação biométrica diante de tentativas de spoofing realizadas com o DeepLiveCam.

Os resultados obtidos indicaram que os mecanismos de reconhecimento facial baseados em embeddings, quando calibrados experimentalmente, conseguiram distinguir o usuário legítimo da identidade sintética no cenário avaliado. Em contrapartida, os experimentos com liveness passivo e challenge-response demonstraram que movimentos faciais, piscadas e respostas a comandos não devem ser considerados evidências isoladas de autenticidade, uma vez que essas características podem ser parcialmente reproduzidas por ferramentas modernas de face swap em tempo real.

Com base nesses resultados, foi desenvolvida uma prova de conceito para monitoramento contínuo de videoconferências, integrando verificação de identidade por embeddings faciais, detecção de manipulação por deepfakes, mecanismos de liveness, avaliação da qualidade da captura e análise temporal das evidências. Diferentemente dos mecanismos tradicionais de autenticação, que normalmente realizam apenas uma validação inicial da identidade, a solução proposta realiza verificações periódicas durante toda a sessão, fornecendo subsídios adicionais para a identificação de possíveis tentativas de personificação.

Como principal contribuição, este trabalho demonstra que a integração de técnicas consolidadas de reconhecimento facial, detecção de manipulação e monitoramento contínuo constitui uma abordagem promissora para aumentar a confiabilidade de entrevistas remotas, reuniões corporativas e outros processos digitais sensíveis, aproximando os estudos de autenticação biométrica de um cenário prático de engenharia social envolvendo deepfakes em tempo real.

AGRADECIMENTOS

O autor agradece à Universidade Federal de Itajubá (UNIFEI) e ao curso de Engenharia de Computação pelo suporte acadêmico ao desenvolvimento deste trabalho. Agradece, em especial, ao Prof. Dr. Otávio de Souza Martins Gomes, pela orientação, dedicação e valiosas contribuições ao longo desta pesquisa. Agradece também aos seus pais e à sua namorada, pelo apoio incondicional, incentivo e compreensão durante toda a trajetória acadêmica e no desenvolvimento deste trabalho.

REFERENCES

[1] I. Goodfellow et al., “Generative Adversarial Nets,” in Advances in Neural Information Processing Systems (NeurIPS), 2014.
[2] S. Bengesi et al., “Advancements in Generative AI: A Comprehensive Review of GANs, GPT, Autoencoders, Diffusion Models and Transformers,” arXiv:2311.10242, 2023.
[3] T. Chakraborty et al., “Ten Years of Generative Adversarial Nets (GANs),” arXiv:2308.16316, 2023.
[4] Y. Nirkin, Y. Keller and T. Hassner, “FSGAN: Subject Agnostic Face Swapping and Reenactment,” arXiv:1908.05932, 2019.
[5] Y. Li et al., “Fine-Grained Face Swapping via Editing with Regional GAN Inversion,” arXiv:2310.15081, 2023.
[6] F. Schroff, D. Kalenichenko and J. Philbin, “FaceNet: A Unified Embedding for Face Recognition and Clustering,” CVPR, 2015.
[7] J. Deng, J. Guo, N. Xue, S. Zafeiriou, “ArcFace: Additive Angular Margin Loss for Deep Face Recognition,” CVPR, 2019.
[8] J. Guo et al., “InsightFace: 2D and 3D Face Analysis Project,” arXiv:2009.00619, 2021.
[9] J. Komulainen, A. Hadid, M. Pietikainen, “Context Based Face Anti-Spoofing,” BTAS, 2013.
[10] B. Dolhansky et al., “The DeepFake Detection Challenge Dataset,” arXiv:2006.07397, 2020.
[11] A. Rössler et al., “FaceForensics++: Learning to Detect Manipulated Facial Images,” ICCV, 2019.
[12] L. Verdoliva, “Media Forensics and DeepFakes: An Overview,” IEEE Journal of Selected Topics in Signal Processing, vol.14, no.5, pp.910–932, 2020.
[13] K. Ng, “Company Worker in Hong Kong Pays Out £20m in Deepfake Video Call Scam,” The Guardian, 2024.
[14] Federal Bureau of Investigation, “FBI Warns of Deepfake Job Applicants Using Stolen Personal Information,” 2022.
[15] DeepInsight, “InsightFace,” GitHub Repository. Disponível em: https://github.com/deepinsight/insightface
[16] YZY-stack, “Effort-AIGI-Detection,” GitHub Repository. Disponível em: https://github.com/YZY-stack/Effort-AIGI-Detection
[17] S. Seferbekov, “DFDC Deepfake Challenge (EfficientNet-B7),” GitHub Repository. Disponível em: https://github.com/selimsef/dfdc_deepfake_challenge
[18] G. Bradski, “The OpenCV Library,” Dr. Dobb’s Journal of Software Tools, 2000.
[19] OpenCV, “Open Source Computer Vision Library,” GitHub Repository. Disponível em: https://github.com/opencv/opencv
[20] Microsoft, “ONNX Runtime,” GitHub Repository. Disponível em: https://github.com/microsoft/onnxruntime